

# SMARTFLOW: SISTEMA DE ANÁLISIS DE FLUJO PEATONAL EN CAMPUS UNIVERSITARIO MEDIANTE VISIÓN POR COMPUTADOR

Victor Manuel Salazar Chaparro, Juan Camilo Casierra Riascos, Brandon Montilla Hernandez  
Universidad Autónoma de Occidente, 2026

## Resumen

Este artículo presenta SmartFlow, un sistema basado en visión por computador diseñado para analizar el flujo peatonal en el campus de la Universidad Autónoma de Occidente (UAO). El sistema emplea el modelo de detección YOLOv8 para identificar personas en imágenes estáticas capturadas en tres zonas del campus: cafetería, sótanos y biblioteca. A partir de las detecciones, se generan mapas de calor de densidad gaussiana y se extraen métricas cuantitativas de movilidad. El sistema fue evaluado sobre un conjunto de 325 imágenes reales. Los resultados muestran que la cafetería presenta el mayor promedio de personas detectadas (2.1 por imagen), seguida de los sótanos (1.3) y la biblioteca (0.5). El 51.7% de las imágenes corresponde a zonas sin actividad detectada, el 42.8% a congestión baja y el 5.5% a congestión media. El tiempo promedio de inferencia fue de 0.97 segundos por imagen utilizando GPU T4. SmartFlow constituye una herramienta de apoyo a la toma de decisiones para la gestión eficiente de espacios en un Campus Universitario Inteligente.

## Palabras Clave

Visión por Computador, YOLOv8, Detección de Personas, Mapa de Calor, Flujo Peatonal, Campus Inteligente, OpenCV.

## I. INTRODUCCIÓN

La gestión eficiente del espacio en entornos universitarios es un desafío que impacta directamente la comodidad, la seguridad y la productividad de estudiantes y docentes. En el campus de la Universidad Autónoma de Occidente, como en muchas instituciones de educación superior, la distribución de personas varía significativamente a lo largo del día y entre zonas, generando momentos de congestión en áreas como la cafetería, los sótanos y la biblioteca.

Actualmente, la mayoría de las decisiones sobre distribución de espacios y horarios se toman sin datos objetivos sobre el comportamiento real del flujo peatonal. Esta carencia de información basada en evidencia limita la capacidad institucional para anticipar cuellos de botella, optimizar rutas de circulación y planificar el uso del espacio de manera proactiva.

Frente a esta problemática surge SmartFlow, un sistema de análisis de flujo peatonal basado en visión por computador. A diferencia de los sistemas tradicionales que dependen de conteo manual o sensores físicos, SmartFlow procesa imágenes estáticas capturadas en diferentes zonas del campus

para detectar automáticamente personas, cuantificar su distribución espacial y generar visualizaciones comprensibles para los tomadores de decisiones.

El sistema utiliza YOLOv8 [1], un modelo de detección de objetos de última generación, combinado con técnicas de procesamiento de imágenes como la ecualización adaptativa de histograma (CLAHE) y la generación de mapas de densidad gaussiana. Los resultados son exportados en formatos estándar (CSV, JSON) para su integración con sistemas de información institucionales.

Este trabajo se enmarca en la línea de Campus Universitario Inteligente y contribuye a la aplicación práctica de técnicas de inteligencia artificial y procesamiento digital de imágenes para resolver problemas reales de movilidad urbana interna.

## II. METODOLOGÍA

### A. Recolección de datos

Se recolectaron 325 imágenes estáticas del campus de la UAO distribuidas en tres zonas de interés: cafetería, sótanos y biblioteca. Las imágenes fueron capturadas en diferentes momentos del día y desde distintos ángulos, representando condiciones variadas de iluminación y densidad de personas. Todas las imágenes fueron almacenadas en Google Drive y organizadas en carpetas separadas por zona para facilitar el análisis diferenciado.

### B. Arquitectura del sistema

SmartFlow sigue un pipeline de procesamiento secuencial compuesto por cinco módulos principales:

- Módulo 1 — Preprocesamiento: Aplicación de CLAHE (Contrast Limited Adaptive Histogram Equalization) en el espacio de color LAB para mejorar el contraste de las imágenes sin saturar las regiones brillantes, facilitando la detección en condiciones de iluminación adversa.
- Módulo 2 — Detección de personas: Uso del modelo YOLOv8n preentrenado en el dataset COCO, configurado para detectar exclusivamente la clase 'persona' (clase 0) con un umbral de confianza de 0.40 e IoU de 0.45.
- Módulo 3 — Generación de mapa de calor: Para cada persona detectada se calcula un kernel gaussiano centrado en el punto de contacto con el suelo (base del bounding box). La superposición de todos los kernels genera un mapa de densidad continuo normalizado en el rango [0, 1].
- Módulo 4 — Análisis zonal: La imagen se divide en una cuadrícula de 3×4 celdas para cuantificar la

distribución espacial de personas. Se clasifica el nivel de congestión global en cinco categorías: sin actividad, baja, media, alta y crítica.

- Módulo 5 — Visualización y exportación: Los resultados se presentan mediante gráficas comparativas por zona y mapas de calor acumulados. Las métricas se exportan en formato CSV y JSON para análisis posterior.

### C. Tecnologías utilizadas

La Tabla I resume las tecnologías y herramientas empleadas en el desarrollo del sistema.

| Categoría         | Tecnología            | Función                                |
|-------------------|-----------------------|----------------------------------------|
| Lenguaje          | Python 3.10           | Lenguaje principal del sistema         |
| Modelo IA         | YOLOv8n (Ultralytics) | Detección de personas en tiempo real   |
| Visión artificial | OpenCV 4.13           | Preprocesamiento CLAHE y overlays      |
| Análisis de datos | Pandas / NumPy        | Métricas, logs y exportación CSV/JSON  |
| Visualización     | Matplotlib / Seaborn  | Mapas de calor y gráficas comparativas |
| Entorno           | Google Colab (GPU T4) | Ejecución del pipeline completo        |
| Almacenamiento    | Google Drive          | Imágenes de entrada y resultados       |

**TABLA I — TECNOLOGÍAS Y HERRAMIENTAS DEL SISTEMA**

### D. Fases del proyecto

El desarrollo del sistema siguió cinco fases iterativas descritas en la Tabla II.

| Fase | Nombre             | Descripción                                                                                 |
|------|--------------------|---------------------------------------------------------------------------------------------|
| 1    | Benchmarking       | Revisión de soluciones existentes para seguimiento de personas y monitoreo de campus.       |
| 2    | Diseño del sistema | Definición de arquitectura, tecnologías y flujo de datos del sistema SmartFlow.             |
| 3    | Implementación     | Codificación de módulos: preprocesamiento, detección YOLOv8, generación de mapas de calor.  |
| 4    | Análisis de datos  | Procesamiento de 325 imágenes reales del campus UAO. Extracción de métricas por zona.       |
| 5    | Visualización      | Generación de mapas de calor acumulados, gráficas comparativas y exportación de resultados. |

**TABLA II — FASES DEL PROYECTO SMARTFLOW**

## III. DESARROLLO

### A. Preprocesamiento de imágenes

Cada imagen es cargada mediante OpenCV y convertida al espacio de color LAB. El canal de luminancia (L) es procesado con CLAHE utilizando un clip limit de 2.0 y una grilla de tiles de 8×8 píxeles. Este enfoque preserva la información de color mientras mejora el contraste local, lo que resulta especialmente útil en las imágenes de los sótanos donde la iluminación artificial genera sombras pronunciadas.

La imagen preprocesada es convertida al espacio RGB antes de ser pasada al modelo de detección, dado que YOLOv8 espera imágenes en formato RGB y OpenCV trabaja por defecto en BGR.

### B. Detección con YOLOv8

Se utilizó la variante YOLOv8n (nano) del modelo YOLO, que ofrece un balance adecuado entre velocidad de inferencia y precisión para el caso de uso planteado. El modelo fue utilizado en modalidad de inferencia sin reentrenamiento (zero-shot), aprovechando los pesos preentrenados sobre el dataset COCO, que incluye la clase 'persona' como una de sus 80 categorías.

Para cada persona detectada, el sistema extrae: el bounding box en coordenadas de píxel (x1, y1, x2, y2), el puntaje de confianza de la detección, y las coordenadas del centroide y del punto de contacto con el suelo (base inferior del bounding box). Este último punto es el que se utiliza como referencia para la generación del mapa de calor, ya que representa más fielmente la posición física de la persona en el espacio.

### C. Generación de mapas de calor

El mapa de calor se genera acumulando kernels gaussianos centrados en la posición de cada persona detectada. La función gaussiana utilizada es:

$$H(x, y) = \Sigma \exp(-((x - cx_i)^2 + (y - cy_i)^2) / (2\sigma^2))$$

Donde (cx<sub>i</sub>, cy<sub>i</sub>) es la posición de la i-ésima persona detectada y  $\sigma = 40$  píxeles controla el radio de influencia de cada detección. El mapa resultante es normalizado al rango [0, 1] y superpuesto sobre la imagen original mediante una combinación ponderada con el colormap JET, con una transparencia de 0.55.

Para el análisis acumulado por zona, los mapas de calor de todas las imágenes de cada zona son sumados antes de la normalización final. Esto permite identificar las subzonas con mayor afluencia histórica dentro de cada área del campus.

### D. Clasificación de congestión

El nivel de congestión de cada imagen se determina en función del número de personas detectadas, siguiendo los umbrales definidos en la Tabla III.

| Nivel         | Rango (personas) | Acción sugerida         |
|---------------|------------------|-------------------------|
| Sin actividad | 0                | Sin intervención        |
| Baja          | 1 – 3            | Monitoreo pasivo        |
| Media         | 4 – 8            | Alerta temprana         |
| Alta          | 9 – 15           | Redistribución de flujo |
| Crítica       | > 15             | Intervención inmediata  |

**TABLA III — NIVELES DE CONGESTIÓN**

#### IV. RESULTADOS

##### A. Métricas globales del sistema

El sistema procesó exitosamente las 325 imágenes del dataset del campus UAO. La Tabla IV resume las métricas globales obtenidas.

| Zona       | Personas (promedio) | Confianza promedio | Nivel de congestión  |
|------------|---------------------|--------------------|----------------------|
| Cafetería  | 2.1                 | 0.464              | Baja – Media         |
| Sótano     | 1.3                 | 0.359              | Baja                 |
| Biblioteca | 0.5                 | 0.212              | Sin actividad – Baja |
| Global     | 1.3                 | 0.345              | Baja (42.8%)         |

**TABLA IV — MÉTRICAS DE DETECCIÓN POR ZONA**

En términos globales, el sistema detectó un total de 422 personas a lo largo de las 325 imágenes, con un promedio de 1.3 personas por imagen. El tiempo promedio de inferencia fue de 0.97 segundos por imagen en entorno Google Colab con GPU T4, lo que demuestra la viabilidad operativa del sistema para análisis en tiempo diferido.

##### B. Análisis por zona

La cafetería presentó la mayor densidad de personas con un promedio de 2.1 detecciones por imagen y una confianza promedio de 0.464, superando el umbral mínimo establecido de 0.40. Este resultado es consistente con la naturaleza de la zona, donde la concentración de personas en horarios de almuerzo genera condiciones de congestión baja a media.

Los sótanos presentaron un promedio de 1.3 personas por imagen con una confianza de 0.359, por debajo del umbral de 0.40. Esta menor confianza se atribuye a las condiciones de iluminación artificial y a los ángulos de captura en espacios cerrados, que dificultan la detección precisa. No obstante, el sistema logró identificar patrones de circulación en esta zona.

La biblioteca mostró el menor nivel de actividad con 0.5 personas promedio por imagen y una confianza de 0.212. Este comportamiento refleja la naturaleza silenciosa y dispersa de la ocupación en esta zona, donde las personas tienden a estar sentadas y en posiciones que dificultan la detección desde ángulos elevados.

##### C. Distribución de congestión

El análisis de la distribución de niveles de congestión sobre el conjunto total de imágenes reveló que el 51.7% de las imágenes presenta ausencia de actividad detectada, el 42.8% corresponde a congestión baja y únicamente el 5.5% alcanza nivel de congestión media. No se registraron niveles de congestión alta ni crítica en el dataset analizado.

Este patrón sugiere que las imágenes fueron capturadas predominantemente en horarios de baja afluencia, o que las zonas seleccionadas no experimentan niveles críticos de congestión en condiciones normales. Esto constituye información de valor para la gestión institucional, al identificar que la mayor presión sobre el espacio se concentra en la cafetería durante franjas horarias específicas.

##### D. Desempeño del modelo

El modelo YOLOv8n demostró un desempeño adecuado para el caso de uso planteado. La variante nano fue seleccionada por su velocidad de inferencia (~1 segundo por imagen en GPU T4), que permite el procesamiento de datasets de tamaño medio en tiempos razonables. Para aplicaciones que requieran mayor precisión, especialmente en condiciones de baja iluminación como los sótanos, se recomienda evaluar la variante YOLOv8s o YOLOv8m.

La aplicación de CLAHE en el preprocesamiento demostró mejorar visualmente la calidad de las imágenes en condiciones de iluminación no uniforme, aunque su impacto cuantificable sobre la tasa de detección requiere un estudio comparativo adicional con y sin preprocesamiento.

#### V. CONCLUSIONES

SmartFlow demuestra que es posible implementar un sistema funcional de análisis de flujo peatonal en un campus universitario utilizando herramientas de visión por computador de código abierto, sin requerir infraestructura de sensores físicos ni inversión en hardware especializado.

Los resultados obtenidos sobre el dataset de 325 imágenes del campus UAO confirman que la cafetería es la zona con mayor densidad de personas y mayor nivel de congestión, seguida de los sótanos y la biblioteca. Esta información puede utilizarse para optimizar los horarios de uso de espacios, reforzar la ventilación o iluminación en zonas de alta densidad, y planificar rutas de circulación alternativas.

El sistema presenta limitaciones en zonas con iluminación artificial intensa o ángulos de captura desfavorables, como se evidencia en la baja confianza de detección en la biblioteca (0.212) y los sótanos (0.359). Estas limitaciones pueden abordarse mediante el ajuste del umbral de confianza, el uso de modelos de mayor capacidad (YOLOv8s/m), o la captura de imágenes desde posiciones más elevadas.

Como trabajo futuro se propone: (1) la integración con cámaras de seguridad existentes para análisis en tiempo real, (2) el entrenamiento de un modelo especializado en

condiciones del campus UAO mediante fine-tuning, (3) la incorporación de análisis temporal para identificar patrones por hora del día, y (4) el desarrollo de un dashboard interactivo para la visualización de resultados por parte del equipo de gestión institucional.

En conclusión, SmartFlow representa un aporte concreto al concepto de Campus Universitario Inteligente, al proveer información objetiva y automatizada sobre el comportamiento del flujo peatonal que puede fundamentar decisiones de planificación espacial basadas en datos reales.

## REFERENCIAS

- [1] G. Jocher, A. Chaurasia y J. Qiu, "Ultralytics YOLOv8," versión 8.0, 2023. [En línea]. Disponible en: <https://github.com/ultralytics/ultralytics>
- [2] A. Bewley, Z. Ge, L. Ott, F. Ramos y B. Upcroft, "Simple Online and Realtime Tracking," en Proc. IEEE ICIP, 2016, pp. 3464–3468.
- [3] K. He, X. Zhang, S. Ren y J. Sun, "Deep Residual Learning for Image Recognition," en Proc. IEEE CVPR, 2016, pp. 770–778.
- [4] M. Moussaïd, D. Helbing y G. Theraulaz, "How simple rules determine pedestrian behavior and crowd disasters," Proc. Natl. Acad. Sci., vol. 108, no. 17, pp. 6884–6888, 2011.
- [5] Y. Zhang, C. Wang, X. Wang, W. Zeng y W. Liu, "FairMOT: On the Fairness of Detection and Re-Identification in Multiple Object Tracking," Int. J. Comput. Vis., vol. 129, pp. 3069–3087, 2021.
- [6] S. Ren, K. He, R. Girshick y J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," IEEE Trans. Pattern Anal. Mach. Intell., vol. 39, no. 6, pp. 1137–1149, 2017.
- [7] Internet of Things and Its Applications to Smart Campus: A Systematic Literature Review, ResearchGate, 2022. [En línea]. Disponible en: <https://www.researchgate.net/publication/366153276>
- [8] M. Braik, A. Sheta y A. Ayesh, "A Comparison Between Particle Swarm Optimization and Genetic Algorithms for Pedestrian Navigation," en Proc. Int. Conf. Comput. Intell., 2008.